



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN

ANÁLISIS, COMPARACIÓN Y RETROALIMENTACIÓN
DE MOVIMIENTO CORPORAL EN VIDEOS DE DANZA

MITOTL IA

MÓDULO 5 — DIPLOMADO EN CIENCIA DE DATOS

DAVID MAGAÑA CELIS

P R O F E S O R :

MTRO. FERNANDO BARRANCO RODRÍGUEZ



05 DE AGOSTO DE 2026

Índice

Resumen ejecutivo	3
1. Introducción	3
2. Planteamiento del problema	3
2.1. Nicho y contexto de uso	3
2.2. Usuario objetivo	4
2.3. Problema y necesidad	4
2.4. Propuesta de valor y caso de uso	4
3. Estrategia de solución	5
3.1. Accionables	5
3.2. Usabilidad y usuarios	5
3.3. Alcance de la versión actual	5
4. Descripción de los datos	6
4.1. Fuentes de referencia y ejecución	6
4.2. Restricciones de uso	6
4.3. Datos derivados	7
5. Análisis exploratorio y calidad de entrada	7
5.1. Calidad de los videos	7
5.2. Detección corporal	8
5.3. Visualizaciones exploratorias	8
6. Ingeniería de variables	8
6.1. Extracción y normalización	8
6.2. Variables de comparación	9
6.3. Preparación para visualización y feedback	9

7. Modelación	9
7.1. Enfoque híbrido de la versión actual	9
7.2. Sincronización temporal con DTW	10
7.3. Score y reglas de retroalimentación	10
8. Pipeline e inferencia	11
9. Resultados	11
9.1. Resultados cuantitativos	11
9.2. Hallazgos y recomendaciones	12
9.3. Visualización comparativa	12
10. Interfaz de uso	13
10.1. Flujo de análisis	13
10.2. Demo precalculada	13
11. Evaluación y reproducibilidad	15
11.1. Pruebas del pipeline	15
11.2. Despliegue	16
11.3. Manejo de errores	16
12. Limitaciones, ética y uso responsable	17
13. Conclusiones y trabajo futuro	17
13.1. Conclusiones	17
13.2. Trabajo futuro	18
Referencias	18

Resumen ejecutivo

Mitotl IA es una herramienta de apoyo para la práctica autónoma de danza. A partir de un video de referencia y un video de ejecución, el sistema identifica diferencias observables en el movimiento corporal y las convierte en una retroalimentación orientada a la práctica. El objetivo no es emitir un juicio artístico profesional, sino ayudar a responder preguntas concretas: en qué momento aparece una diferencia, qué parte del cuerpo conviene revisar y qué acción puede intentar la persona usuaria.

La versión actual trabaja con una sola persona y requiere que el cuerpo completo sea visible. Su flujo combina validación de video, extracción de pose, variables geométricas, sincronización temporal y reglas de retroalimentación. El resultado se presenta mediante un score orientativo, indicadores por parte del cuerpo, visualizaciones comparativas, clips críticos y un asistente conversacional básico. La validación se realizó con un video de referencia y una ejecución propia; por tanto, no constituye una evaluación general de desempeño artístico.

1. Introducción

Aprender una coreografía mediante videos permite practicar en horarios y espacios diversos, pero también desplaza a la persona practicante la tarea de detectar sus propios errores. La comparación visual directa puede ser insuficiente cuando la diferencia ocurre durante un instante, afecta una articulación específica o se presenta con una velocidad distinta entre la referencia y la ejecución.

Este documento presenta el diseño y desarrollo de Mitotl IA como una solución aplicada de ciencia de datos. Se describe el problema de uso, la estrategia de la versión actual, la procedencia de los datos, el procesamiento previsto y la evidencia de la aplicación. El reporte distingue entre lo que está implementado y las capacidades que permanecen como trabajo futuro.

2. Planteamiento del problema

2.1. Nicho y contexto de uso

El nicho de uso es el aprendizaje autónomo de danza mediante videos de referencia. Incluye a personas que practican coreografías, ejercicios o tendencias difundidas en plataformas como TikTok y YouTube, así como a quienes siguen una clase grabada sin contar necesariamente

con un espejo, un salón especializado o la observación continua de un instructor.

En este contexto, el video de referencia funciona como una guía visual y el video de ejecución como evidencia de la práctica. La necesidad no es ordenar a las personas por nivel ni establecer una calificación universal de la danza, sino ofrecer información localizada que permita repetir y ajustar una secuencia.

2.2. Usuario objetivo

La persona usuaria objetivo practica de manera individual y puede tener experiencia inicial o intermedia. Cuenta con un teléfono o una computadora para cargar o grabar un video, desea aprender una secuencia concreta y necesita una explicación comprensible sobre sus principales oportunidades de mejora.

Se asume que la persona puede colocar la cámara de frente y mantener el cuerpo completo dentro del encuadre. Este supuesto es importante porque la versión actual no está diseñada para grupos, personas parcialmente visibles ni situaciones en las que una parte importante del cuerpo quede tapada o fuera de la vista.

2.3. Problema y necesidad

El problema es que una persona puede repetir una coreografía sin saber con precisión qué está fallando. La observación subjetiva permite reconocer que algo no coincide, pero no siempre permite localizar el momento, distinguir si la diferencia proviene de brazos, piernas o torso, ni convertir esa observación en una instrucción práctica.

De este problema se desprenden cuatro necesidades: localizar momentos específicos de dificultad; identificar las partes del cuerpo asociadas; recibir una explicación clara y accionable; y contar con una guía que permita volver a practicar la sección relevante. Mitotl IA atiende estas necesidades mediante comparación corporal y temporal, sin presentarse como sustituto de una evaluación profesional.

2.4. Propuesta de valor y caso de uso

La propuesta de valor de Mitotl IA es transformar dos videos en una guía de práctica localizada. La persona carga un video de referencia y un video de ejecución, espera el análisis y consulta un resultado compuesto por similitud corporal, similitud temporal, hallazgos y recomendaciones. También puede revisar una visualización comparativa y preguntar al asistente sobre la interpretación del resultado.

El caso de uso principal es una sesión de práctica individual: seleccionar una secuencia, grabar o cargar la ejecución, revisar las diferencias más relevantes y repetir la sección con base en la retroalimentación. El sistema no evalúa calidad artística profesional, musicalidad, expresividad o intención escénica. Su salida es una aproximación computacional orientada a comparar movimiento observable.

3. Estrategia de solución

3.1. Accionables

La estrategia prioriza resultados que puedan convertirse en acciones inmediatas. A partir del análisis, la persona puede: revisar el segmento temporal con mayor diferencia; concentrarse en una parte del cuerpo; observar la referencia y la ejecución en paralelo; repetir la sección crítica; y utilizar el asistente para aclarar el significado de un indicador.

El score general se comunica como una señal de orientación y no como una calificación definitiva. La interfaz debe favorecer la interpretación por evidencia: score, momento, parte del cuerpo y recomendación se presentan juntos para evitar que un número aislado sea la única conclusión.

3.2. Usabilidad y usuarios

El flujo está organizado alrededor de cuatro momentos: cargar los videos, ejecutar el análisis, revisar resultados y consultar la retroalimentación. La interfaz conserva una navegación por pestañas para separar videos, resultados, visualizaciones y asistente. Para una demostración, también se dispone de una sesión precalculada que permite revisar la interfaz sin esperar nuevamente todo el procesamiento.

Los mensajes de la aplicación distinguen advertencias de la referencia y de la ejecución. Esto es relevante cuando un video contiene frames que no pudieron decodificarse o momentos sin detección corporal: la advertencia informa una condición técnica sin convertirla automáticamente en un juicio sobre la persona.

3.3. Alcance de la versión actual

La versión actual incluye análisis de videos cargados, extracción de pose con MediaPipe, comparación de movimiento, alineación temporal, score orientativo, recomendaciones, visualización comparativa, clips críticos y un asistente básico. La captura directa mediante

cámara y el feedback en tiempo real no están implementados en esta versión; la entrada se realiza mediante archivos de video.

Quedan fuera del alcance inmediato la evaluación artística profesional, el análisis de varias personas, la personalización longitudinal, los planes de práctica adaptativos, la sincronización musical avanzada y los modelos especializados entrenados con etiquetas de calidad de danza. Estas capacidades pueden explorarse en versiones futuras después de reunir datos autorizados y criterios de evaluación adecuados.

4. Descripción de los datos

4.1. Fuentes de referencia y ejecución

La fuente académica principal para el video de referencia es AIST Dance Video Database, una colección de videos de danza utilizada para construir y validar el flujo inicial. Se selecciona una secuencia con una persona, vista frontal y cuerpo completo visible. La referencia se emplea para probar la extracción de pose, la comparación corporal y la sincronización temporal, no para definir una verdad absoluta sobre cómo debe bailar una persona.

El video de ejecución representa la práctica propia que se desea comparar. Para validar el flujo se utilizó una ejecución grabada por la persona desarrolladora, distinta del video de referencia. Esta evidencia permite revisar el funcionamiento de la comparación, pero no basta para medir aprendizaje, generalización o calidad de danza en una población amplia.

Como posible fuente complementaria se documenta AIST++, pero sus anotaciones no se descargaron ni forman parte del flujo actual. La referencia queda como una línea futura para explorar landmarks, confianza y cobertura corporal mediante un mapeo entre sus 17 keypoints COCO y los 33 landmarks de MediaPipe. No se utiliza como conjunto etiquetado de personas que bailan bien o mal.

4.2. Restricciones de uso

El uso de los videos de AIST está sujeto a sus términos de uso y a las condiciones académicas de la fuente AIST Dance Video Database, [s.f.-a](#), [s.f.-b](#). Los archivos de video utilizados localmente no deben redistribuirse dentro del repositorio. Por esa razón, el proyecto conserva metadatos y rutas esperadas, pero excluye los videos privados o descargados de los artefactos versionados.

Los videos aportados por una persona usuaria deberán contar con autorización o una

licencia compatible con el análisis. La aplicación debe tratar estos archivos como entradas temporales de procesamiento y evitar presentarlos como material público. La documentación separa explícitamente procedencia, permiso de uso y datos derivados para que una ejecución reproducible no dependa de un archivo privado.

4.3. Datos derivados

Mitotl IA genera datos derivados a partir de cada video. Entre ellos se encuentran los landmarks corporales, coordenadas normalizadas, visibilidad de puntos, ángulos articulares, trayectorias, marcas de tiempo, segmentos temporales, diferencias entre referencia y ejecución y scores. Estos datos no son una nueva fuente externa: son resultados calculados por el pipeline.

La representación derivada permite comparar movimiento sin depender directamente de la resolución o del tamaño original del video. También permite producir evidencia comprensible para la interfaz, como diferencias por parte del cuerpo y momentos críticos. En etapas posteriores se documentarán con mayor detalle las variables, la normalización, la modelación y las reglas de retroalimentación.

5. Análisis exploratorio y calidad de entrada

5.1. Calidad de los videos

Antes de analizar el movimiento, el sistema inspecciona la extensión, la duración, el FPS, la resolución y la cantidad de frames declarada por el contenedor. Después genera una copia temporal de análisis con una altura máxima de 480 píxeles y un FPS objetivo de 15. Para videos de más de cinco minutos utiliza 8 FPS. Esta preparación reduce el costo computacional y conserva el archivo original sin modificarlo; el video comparativo de salida puede generarse posteriormente a 30 FPS.

La validación distingue entre errores que impiden continuar y advertencias que permiten generar resultados parciales. Por ejemplo, si el video reporta más frames de los que finalmente pueden decodificarse, se informa la diferencia y se continúa con los frames disponibles. La advertencia es relevante para interpretar el final del video, pero no implica que todo el análisis deba descartarse.

5.2. Detección corporal

MediaPipe Pose extrae hasta 33 landmarks por frame Google, [s.f.](#) Para cada punto se conservan sus coordenadas x , y , z y un valor de visibilidad. La exploración revisa si existe detección, si los landmarks tienen la cantidad esperada y si los índices de frame y timestamps mantienen continuidad.

Como resumen descriptivo del conjunto de referencias disponible, el archivo de calidad de pose registra diez videos. Nueve contienen todos sus frames procesados y uno presenta una detección faltante; las tasas de detección se encuentran entre 99.9 % y 100 %, la visibilidad promedio entre 0.8389 y 0.9843, y el FPS original es 59.94. Este resumen permite identificar que la principal variación de entrada está en la visibilidad de los puntos, no en una pérdida generalizada de frames.

El análisis se limita a una persona con el cuerpo completo visible y una cámara frontal o aproximadamente frontal. Cuando un frame no contiene detección, se conserva su posición temporal para no desplazar artificialmente la secuencia. Los huecos breves pueden tratarse durante la construcción de la secuencia angular; los huecos largos se reportan como una condición que reduce la confiabilidad.

5.3. Visualizaciones exploratorias

Las visualizaciones exploratorias superponen landmarks sobre frames seleccionados y contrastan poses de referencia y ejecución. También permiten inspeccionar el comportamiento de brazos, piernas, torso y cabeza, además de ubicar los segmentos con mayor diferencia. Estas vistas sirven como control de calidad: antes de interpretar un score se verifica que la detección corresponda realmente a la persona y al movimiento observado.

6. Ingeniería de variables

6.1. Extracción y normalización

La extracción conserva coordenadas y marcas de tiempo por frame. Para hacer comparables dos videos con distinta escala o distancia a la cámara, las coordenadas se trasladan usando el centro de las caderas como origen y se escalan con la distancia entre el centro de hombros y el centro de caderas. Así, la comparación se concentra en la configuración relativa del cuerpo y no únicamente en su posición dentro de la imagen.

Además de las coordenadas normalizadas, se calculan ocho ángulos articulares: codos,

hombros, rodillas y caderas de ambos lados. La visibilidad se conserva como diagnóstico de calidad. También se derivan velocidades angulares y velocidades de landmarks cuando existen timestamps válidos, aunque el score principal utiliza la información corporal y temporal definida para esta versión.

6.2. Variables de comparación

La comparación alineada calcula diferencias euclidianas en el plano visible XY y una diferencia espacial auxiliar en XYZ para cada landmark compartido. Las diferencias se resumen por frame, landmark y parte corporal. Las partes amplias usadas en los resultados son brazos, piernas, torso y cabeza; los brazos y piernas se obtienen agrupando sus lados izquierdo y derecho.

La secuencia de ocho ángulos se utiliza para sincronizar referencia y ejecución. Las variables temporales incluyen pares de frames alineados, desplazamiento de tiempo, duración de cada segmento, razón entre duraciones y similitud temporal. La coreografía se divide en segmentos de aproximadamente dos segundos para que los hallazgos puedan relacionarse con momentos revisables por la persona usuaria.

6.3. Preparación para visualización y feedback

Una diferencia corporal no se presenta directamente como una lista de coordenadas. Se transforma en una similitud acotada mediante $s(d) = 1/(1 + d)$, se agrupa por parte del cuerpo y se convierte a una escala de 0 a 100. Los segmentos débiles se ordenan por sus diferencias y se acompañan con tiempos de referencia y ejecución.

La estructura de resultados alimenta tanto las tarjetas y tablas de la interfaz como las recomendaciones y el contexto del asistente. Si falta información suficiente, el pipeline conserva el error o la advertencia por etapa para que la interfaz comunique qué ocurrió y si el resultado puede interpretarse con cautela.

7. Modelación

7.1. Enfoque híbrido de la versión actual

La solución combina componentes deterministas y un modelo preentrenado. MediaPipe Pose estima landmarks; las variables normalizadas y angulares describen el movimiento; la comparación geométrica calcula diferencias; DTW alinea secuencias realizadas a velocidades

distintas; y las reglas convierten los resultados en retroalimentación. Este enfoque funciona como una línea base explicable: cada salida puede rastrearse hasta un frame, landmark, segmento o regla, y no requiere entrenar un clasificador de calidad artística. La evaluación se realiza con scores corporales, similitud temporal, pares DTW, segmentos débiles, revisión visual y pruebas unitarias; no se reporta exactitud de clasificación porque el proyecto no cuenta con etiquetas de calidad artística.

7.2. Sincronización temporal con DTW

Dynamic Time Warping (DTW) encuentra un camino de correspondencias entre la secuencia angular de referencia y la de ejecución Berndt y Clifford, 1994. Antes de calcularlo, cada uno de los ocho ángulos se estandariza usando la media y desviación combinadas de ambas secuencias. Esto reduce el efecto de escalas distintas entre variables y permite comparar la forma temporal del movimiento.

La implementación conserva el camino DTW y lo traduce a pares de frames y timestamps. Los frames sin pose o con ángulos incompletos se mantienen en la línea temporal; las ausencias breves se interpolan y un hueco mayor a dos segundos se rechaza para evitar fabricar una trayectoria corporal poco confiable. El camino se proyecta después en segmentos de dos segundos.

7.3. Score y reglas de retroalimentación

El score general combina similitud corporal y similitud temporal con pesos explícitos:

$$\text{score general} = 100 (0.80 \text{ similitud corporal} + 0.20 \text{ similitud temporal}) .$$

La similitud corporal se calcula como el promedio de los grupos brazos, piernas, torso y cabeza. La similitud temporal se obtiene de la alineación y de la coincidencia de duración de los segmentos. El resultado se comunica como preliminar y orientativo, no como porcentaje de talento, error absoluto o calidad profesional.

Las reglas priorizan los hallazgos con mayor diferencia y los traducen en mensajes de práctica: revisar una parte corporal, volver a un segmento temporal o repetir la secuencia observando una articulación. El asistente explica estos resultados sin inventar métricas que no estén disponibles.

8. Pipeline e inferencia




Figura 1: Flujo general de inferencia de Mitotl IA.

El pipeline recibe dos videos y produce una sesión estructurada. Primero valida y prepara cada entrada; después extrae pose y variables; construye la alineación temporal; compara landmarks en cada par DTW; calcula scores y segmentos; genera feedback; y entrega resultados a la interfaz, los clips y el asistente.

Los errores se controlan por etapa. Una entrada inválida detiene el análisis con un mensaje específico; una copia temporal incompleta conserva los frames decodificados y advierte sobre el tramo omitido; un frame sin detección no se confunde con un frame inexistente; y un hueco largo de pose evita que DTW continúe con datos artificiales. Esta separación permite distinguir un problema del archivo de un resultado bajo de similitud.

9. Resultados

9.1. Resultados cuantitativos

La sesión guardada para la demostración compara una referencia AIST con una ejecución propia. La referencia contiene 719 frames y la ejecución 947 frames. El resultado es preliminar y se interpreta como una guía de práctica, no como una medición profesional. El análisis completo conserva seis segmentos; la vista resumida de la demo muestra los segmentos principales para facilitar la revisión.

El score corporal promedio fue 66.44 % y la similitud temporal fue 64.39 %. La ponderación utilizada fue 80 % para similitud corporal y 20 % para similitud temporal, de acuerdo con la definición de la versión actual.

Cuadro 1: Resumen cuantitativo de la sesión guardada.

Indicador	Resultado	Lectura
Score general	66.03	Orientativo
Brazos	47.49	Área prioritaria
Piernas	65.13	Revisar trayectoria
Torso	74.21	Mayor coincidencia relativa
Cabeza	78.91	Mayor coincidencia relativa
Similitud temporal	64.39 %	Diferencias de ritmo
Pares alineados por DTW	1,098	Correspondencias temporales
Segmento más débil	2	1.99–3.97 s de referencia

9.2. Hallazgos y recomendaciones

El resultado identifica los brazos como la principal oportunidad de mejora, con 47.49 % de similitud agrupada. En los registros de mayor diferencia aparecen landmarks de la mano derecha alrededor de los 2.35 segundos de referencia y 2.85 segundos de ejecución. También se observan diferencias en la trayectoria de las piernas, particularmente cerca del primer segmento.

La recomendación generada para los brazos es revisar su trayectoria; para las piernas, revisar posición y trayectoria; y para el segmento temporal 2, practicar el cambio de ritmo. Estas frases no describen una corrección artística absoluta: indican qué evidencia conviene revisar primero dentro de esta comparación.

9.3. Visualización comparativa

El repositorio conserva una visualización comparativa completa y tres clips de momentos críticos en los recursos versionados de la demo. Estos archivos se cargan en la pestaña de visualizaciones cuando se revisa la sesión guardada. La aplicación también permite descargar los clips para inspeccionar la diferencia fuera de la interfaz.

Como evidencia del control de calidad de pose, la Figura 2 reúne la validación de landmarks en los videos de referencia disponibles.



Figura 2: Validación visual de landmarks corporales en videos de referencia.

10. Interfaz de uso

10.1. Flujo de análisis

La interfaz organiza la experiencia en cuatro pestañas: Videos, Resultados, Visualizaciones y Asistente. En Videos se cargan la referencia y la ejecución mediante archivos de video. El botón de análisis inicia la preparación, extracción, alineación y cálculo de resultados; el estado del proceso comunica la etapa actual.

En Resultados se presentan el score general, los scores por brazos, piernas, torso y cabeza, la similitud temporal, los hallazgos y las recomendaciones. Visualizaciones muestra la comparación sincronizada, los clips críticos y, cuando aplica, las advertencias separadas para referencia y ejecución. Asistente permite preguntar sobre la sesión y recibe el contexto de scores, segmentos débiles y recomendaciones. La pestaña Videos recibe archivos de video; no ofrece captura directa desde la cámara.

La Figura 3 muestra la pantalla de resultados de la sesión precalculada. La información se presenta en tarjetas y bloques de lectura rápida para que la persona identifique primero el score general y después las partes del cuerpo que conviene practicar.

La Figura 4 documenta la pestaña de visualizaciones. El video comparativo y los clips se sirven desde archivos precalculados; por ello, esta revisión no vuelve a ejecutar la extracción de pose ni la alineación temporal.

10.2. Demo precalculada

La aplicación puede cargar la sesión guardada desde el JSON versionado de la demo. Esta opción permite demostrar la navegación, los resultados y los videos comparativos sin volver



Figura 3: Pestaña de resultados con la sesión demo activada.




Figura 4: Pestaña de visualizaciones con el video comparativo sincronizado.

a ejecutar el procesamiento completo. La sesión precalculada está identificada como demo y no sustituye el flujo de análisis con videos nuevos.

La demo utiliza recursos ligeros ya incluidos en el repositorio: el resumen JSON y los cuatro videos comparativos. Esto mantiene el tiempo de espera de la demostración bajo control; el análisis de una sesión nueva puede tardar más dependiendo de la duración, resolución, decodificación y disponibilidad de recursos.

Finalmente, la Figura 5 muestra el asistente dentro de la misma interfaz. Su función es explicar los resultados y orientar la práctica; no reemplaza el análisis determinista ni una evaluación profesional.




Figura 5: Pestaña del asistente educativo durante la revisión de la demo.

11. Evaluación y reproducibilidad

11.1. Pruebas del pipeline

El repositorio incluye pruebas unitarias para validación de archivos, preparación de videos, extracción de variables, alineación, comparación, score, feedback, generación de reportes, visualizaciones y contrato del agente. También existe una sesión dorada en `tests/golden_session.json`, que fija 1,098 pares DTW, score general de 66.03 %, seis segmentos y los pesos 0.80/0.20.

La validación aplicada se complementa con archivos derivados de la sesión disponibles en

el entorno de trabajo: resumen de comparación, resumen de alineación, scores y calidad de pose. Estos artefactos no están versionados en Git porque dependen de videos locales excluidos del repositorio; sirven como evidencia de esta ejecución, pero no garantizan por sí solos la reproducción exacta desde un clon limpio. La ejecución propia permitió comprobar el flujo completo con entradas distintas, mientras que la imagen de landmarks y los clips sirven para revisar visualmente la salida.

La organización del análisis está reflejada en los notebooks numerados del repositorio: inventario y validación de fuentes, extracción de pose, normalización, comparación, sincronización DTW, score y reglas, y agente de retroalimentación. Cada notebook conserva la construcción paso a paso de la etapa correspondiente y la aplicación reúne esas decisiones en un flujo de inferencia reproducible.

11.2. Despliegue

La aplicación se ejecuta localmente con el entorno y dependencias declaradas en los archivos del proyecto. La interfaz se implementa con Streamlit y el procesamiento utiliza OpenCV, MediaPipe, NumPy, Pandas y DTW. El repositorio contiene la configuración necesaria para intentar un despliegue en Streamlit Community Cloud y conserva el flujo de análisis y la demo precalculada; el estado de una instancia remota depende de su entorno de ejecución.

Durante las pruebas de despliegue se identificó que MediaPipe podía intentar acceder a un modelo dentro de un directorio sin permisos de escritura. En el código versionado no existe una rutina propia que copie o redirija ese modelo a una ruta temporal; por ello, esta condición debe considerarse una dependencia del entorno Cloud y una limitación de despliegue pendiente de resolver. Localmente, la extracción utiliza directamente MediaPipe Pose y no modifica los videos de entrada.

11.3. Manejo de errores

Los frames sin detección se conservan como parte de la secuencia temporal y generan advertencias cuando afectan la interpretación. Los videos truncados o con menos frames decodificables continúan con los frames disponibles, informando el tramo omitido. Los huecos de pose mayores a dos segundos se consideran insuficientes para interpolar y detienen la alineación de esa secuencia.

La extracción de pose encapsula los errores de MediaPipe y los presenta con la etapa correspondiente. La ausencia de API key no debe impedir consultar los resultados deterministas: la interfaz puede mostrar scores, hallazgos y recomendaciones aunque el asistente

conversacional no esté disponible.

12. Limitaciones, ética y uso responsable

Mitotl IA tiene limitaciones que deben acompañar cualquier interpretación de sus resultados. Primero, analiza una sola persona y depende de que el cuerpo completo permanezca visible. Cambios de cámara, baja iluminación, ropa que dificulte la detección, partes del cuerpo fuera de cuadro o movimientos muy rápidos pueden reducir la calidad de los landmarks.

Segundo, el score compara variables observables entre dos videos; no mide talento, musicalidad, expresividad, intención escénica ni calidad artística profesional. Tampoco debe utilizarse para evaluar o clasificar personas. La sesión documentada es una evidencia de funcionamiento con una ejecución propia, no un estudio con muestra de usuarios ni una evaluación estadística de generalización.

Tercero, AIST no se trata como un conjunto etiquetado de desempeño correcto o incorrecto. Los videos se utilizan con respeto a sus términos de uso y no deben redistribuirse. Los videos de usuarios requieren autorización compatible, deben manejarse como entradas privadas y no deben incorporarse al repositorio sin una decisión explícita de licencia y privacidad.

13. Conclusiones y trabajo futuro

13.1. Conclusiones

La versión documentada demuestra un flujo reproducible para comparar una referencia de danza con una ejecución propia. La combinación de landmarks, variables normalizadas, DTW, scores y reglas permite convertir una diferencia visual general en puntos de revisión más concretos. En la sesión guardada, los brazos y el segundo segmento temporal concentran las principales oportunidades de práctica.

El valor de la herramienta está en localizar y explicar momentos de la comparación, no en reemplazar a un instructor ni producir una calificación definitiva. La interfaz, los clips y la sesión precalculada hacen posible presentar el resultado de manera comprensible y verificable.

13.2. Trabajo futuro

Como trabajo futuro se consideran el análisis de varias personas, un historial de sesiones, personalización de recomendaciones, métricas de ritmo y suavidad, sincronización con música, mayor tolerancia a cambios de cámara y modelos temporales especializados. Estas extensiones requieren datos autorizados, criterios de evaluación más amplios y pruebas con usuarios reales.

Referencias

- AIST Dance Video Database. (s.f.-a). *AIST Dance Video Database*. Consultado el 5 de agosto de 2026, desde <https://aistdancedb.ongaaccel.jp/>
- AIST Dance Video Database. (s.f.-b). *Terms of Use*. Consultado el 5 de agosto de 2026, desde https://aistdancedb.ongaaccel.jp/terms_of_use/
- Berndt, D. J., & Clifford, J. (1994). Using Dynamic Time Warping to Find Patterns in Time Series. *Proceedings of the AAAI Workshop on Knowledge Discovery in Databases*, 359-370.
- Google. (s.f.). *MediaPipe Pose*. Consultado el 5 de agosto de 2026, desde https://ai.google.dev/edge/mediapipe/solutions/vision/pose_landmarker